Белорусский государственный университет
Факультет прикладной математики и информатики

Кафедра информационных систем управления

РАСЧЕТНО-ГРАФИЧЕСКАЯ РАБОТА № 2

Статистические исследования на базе частотных словарей
русского и английского языков

Выполнил:
студент [курс] курса [группа] группы
[ФИО студента]

Минск, 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....3
ЗАДАНИЕ 1. ЗАКОН ЦИПФА.....4
ЗАДАНИЕ 2. ЭМПИРИЧЕСКИЙ ЗАКОН ЦИПФА.....7
ЗАДАНИЕ 3. РАСЧЕТ КОЭФФИЦИЕНТА D ЖУЙАНА.....11
ЗАКЛЮЧЕНИЕ.....15
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....16

ВВЕДЕНИЕ

Цель работы — статистическое исследование частотных словарей, построенных по корпусу русской и английской Википедии. Исследование включает проверку закона Ципфа, проверку эмпирического закона Ципфа для служебных слов и расчет коэффициента D Жуйана.

Исходные данные — четыре частотных словаря проекта nlp_uni: русский и английский, каждый в двух вариантах — без лемматизации и с лемматизацией. Словари содержат абсолютные частоты слов (словоформ или лемм), общее число токенов и число уникальных единиц. Объем каждого словаря — около 5 млн словоупотреблений.

Для расчетов использовались язык программирования Python, библиотеки pandas, NumPy, SciPy и Matplotlib. Все вычисления и графики воспроизводятся в ноутбуках 01_zipf_law.ipynb, 02_zipf_empirical_function_words.ipynb и 03_juilland.ipynb.

Отчет состоит из трех заданий. В первом задании проверяется основной закон Ципфа, во втором — его эмпирический вариант для служебных слов, в третьем — равномерность распределения слов по сегментам корпуса с помощью коэффициента Жуйана.

ЗАДАНИЕ 1. ЗАКОН ЦИПФА

Закон Ципфа утверждает, что произведение частоты слова f на его ранг r в частотном списке есть приблизительно постоянная величина:

$$f \cdot r = c,$$

где f — частота встречаемости слова в тексте; r — ранг слова в частотном списке; c — эмпирическая постоянная (коэффициент Ципфа).

Чем ближе произведение f · r к постоянной величине во всем диапазоне рангов, тем лучше выполняется закон. На практике закон Ципфа выполняется приближенно: наиболее заметные отклонения наблюдаются для самых частых слов и для слов с очень малой частотой.

Характеристики использованных частотных словарей приведены в таблице 1.

Таблица 1 – Характеристики частотных словарей

Словарь	Язык	Лемматизация	Токенов	Уникальных слов
Русский, без лемматизации	Русский	Нет	4 982 552	314 763
Русский, с лемматизацией	Русский	Да	5 000 251	181 819
Английский, без лемматизации	Английский	Нет	5 002 249	142 303
Английский, с лемматизацией	Английский	Да	5 002 249	124 040

Ранг присваивался словам по убыванию частоты; при совпадении частот использовался алфавитный порядок. Для каждого слова вычислялось произведение f · r. Показатели оценивались в диапазоне рангов 100–5000, где закон Ципфа обычно наиболее устойчив. В качестве коэффициента c использовалась медиана произведения f · r в этом диапазоне. Дополнительно методом наименьших квадратов оценивалась степенная зависимость f(r) = C · r^(−α): наклон α в координатах log10 f от log10 r должен быть близок к −1.

Сводные результаты проверки закона Ципфа приведены в таблице 2.

Таблица 2 – Показатели закона Ципфа (ранги 100–5000)

Словарь	c	Наклон α	R^2	Доля в ±25 % от c	CV(f·r)
Русский, без лемматизации	591 965	-0,844	0,999	91,5 %	0,117
Русский, с лемматизацией	656 775	-1,035	0,990	99,7 %	0,087
Английский, без лемматизации	581 872	-0,929	0,992	96,4 %	0,080
Английский, с лемматизацией	567 200	-1,050	0,984	99,1 %	0,115

На рисунке 1 показаны графики для русского языка, на рисунке 2 — для английского. Верхние панели содержат эмпирические точки в логарифмических координатах, теоретическую прямую f = c / r и аппроксимирующую степенную зависимость. Нижние панели показывают произведение f · r: горизонтальная линия соответствует медианному значению c, а серая полоса отмечает диапазон рангов 100–5000.

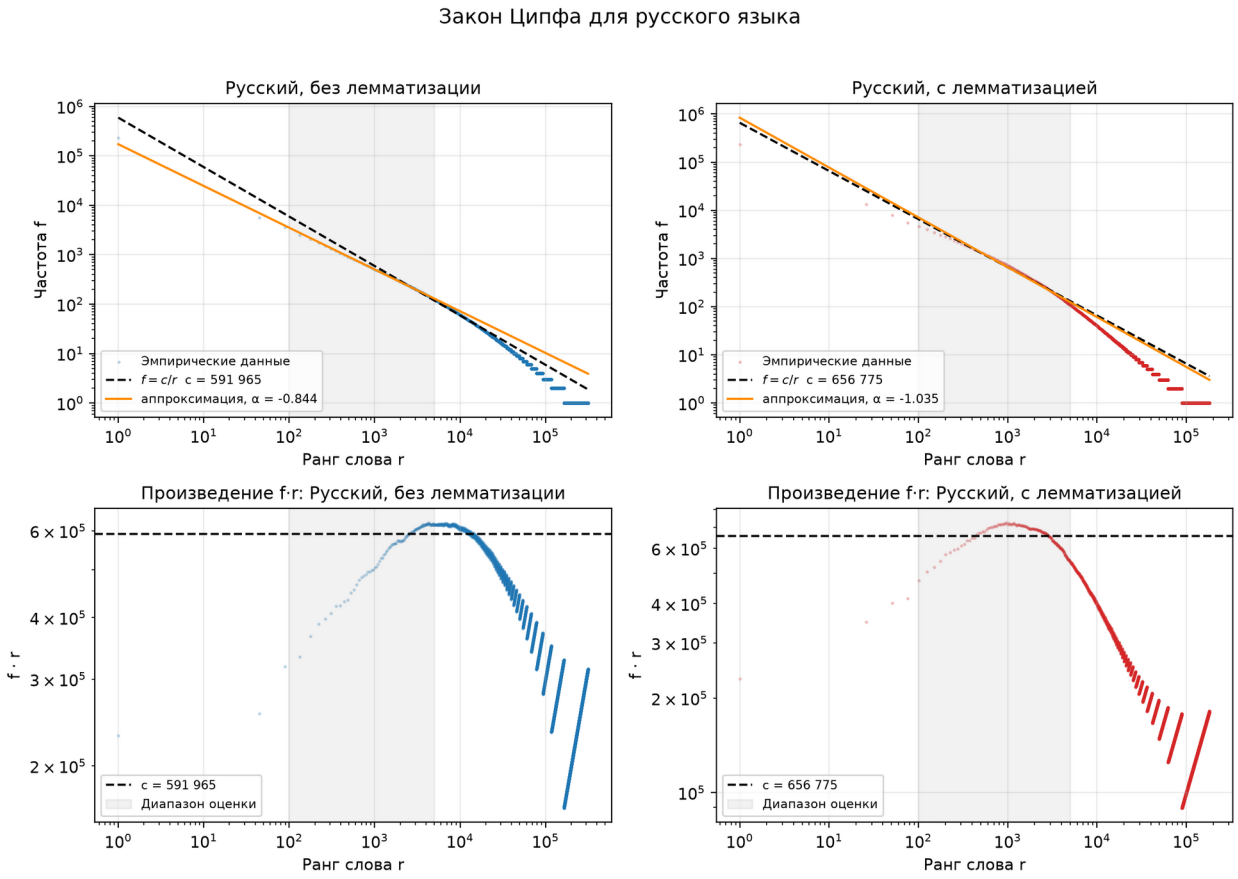


Рисунок 1 – Закон Ципфа для русского языка: частота от ранга и произведение f · r

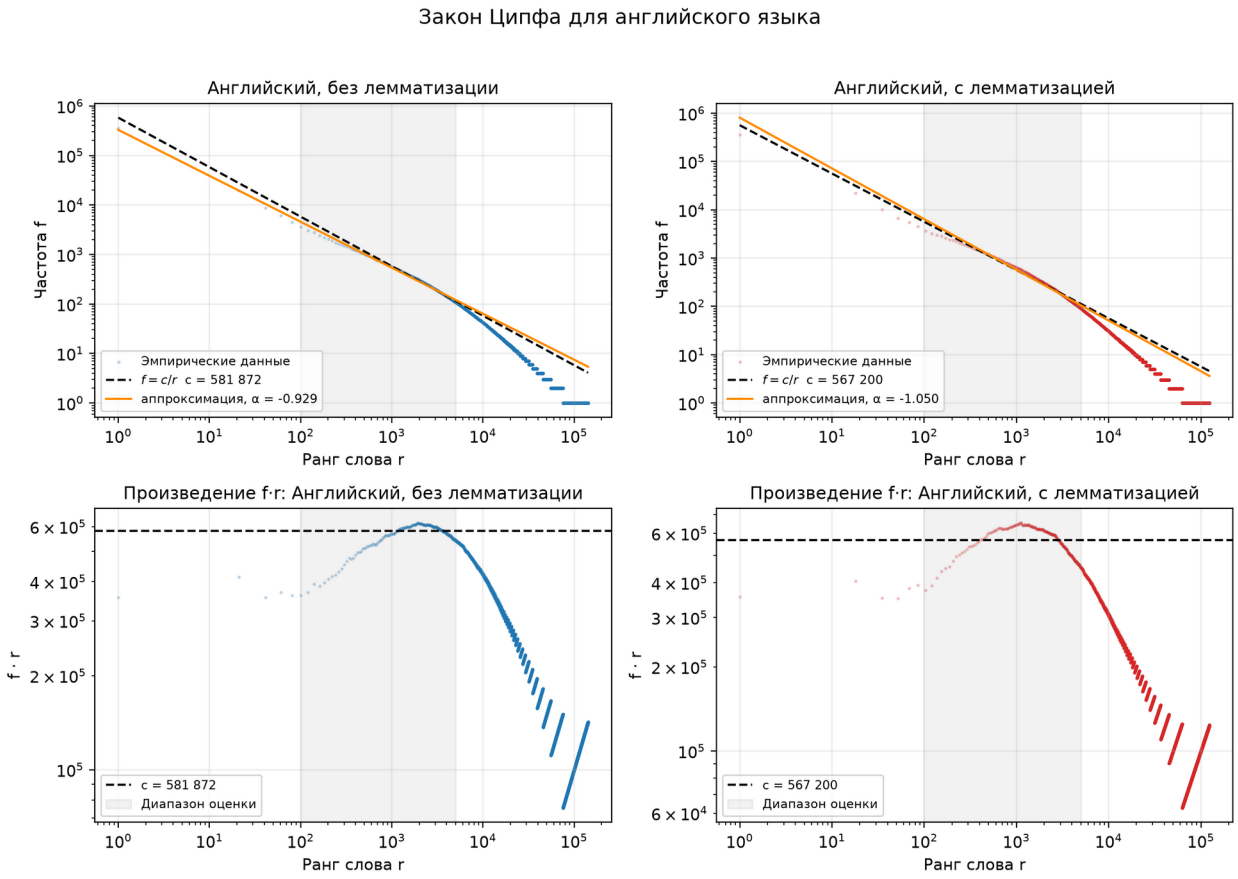


Рисунок 2 – Закон Ципфа для английского языка: частота от ранга и произведение f · r

Для русского словаря без лемматизации медиана c составила 591 965, наклон α = -0,844, R^2 = 0,999; для русского словаря с лемматизацией — c = 656 775, α = -1,035, R^2 = 0,990. Для английского словаря без лемматизации c = 581 872, α = -0,929, R^2 = 0,992; с лемматизацией — c = 567 200, α = -1,050, R^2 = 0,984.

Во всех четырех случаях коэффициент детерминации R^2 превышает 0,98, а наклон α близок к −1 (от −0,84 до −1,05). Доля слов, для которых произведение f · r отличается от медианного значения не более чем на 25 %, составляет от 91,5 до 99,7 %. Это означает, что закон Ципфа выполняется как приближенная закономерность: в средней части частотного списка произведение f · r действительно ведет себя как почти постоянная величина, а на краях списка наблюдаются систематические отклонения. Наиболее частые слова дают повышенное произведение f · r, а редкие слова — пониженное, что связано с конечным объемом корпуса и особенностями токенизации.

Вывод по заданию 1: закон Ципфа для построенных частотных словарей выполняется приближенно. Коэффициент Ципфа c зависит от языка и от способа подготовки словаря (с лемматизацией или без нее) и составляет примерно 0,57–0,66 млн для русского и английского языков в рассматриваемом диапазоне рангов.

ЗАДАНИЕ 2. ЭМПИРИЧЕСКИЙ ЗАКОН ЦИПФА

Эмпирический закон Ципфа (закон аббревиатуры) утверждает, что длина слова обратно пропорциональна его частоте: более короткие слова в среднем встречаются чаще, а длинные — реже. Проверка выполнялась на списке служебных слов: предлогов, союзов, частиц, местоимений и вспомогательных глаголов.

Список служебных слов был составлен вручную и затем отфильтрован по наличию в соответствующем частотном словаре. Для русского языка в анализе участвовало до 151 служебного слова, для английского — до 164 (точное число зависит от варианта словаря и лемматизации). Для каждого слова определялись длина L в символах, абсолютная частота f, относительная частота на 1 млн токенов и ранг в словаре.

Степень связи оценивалась коэффициентами корреляции Пирсона и Спирмена. Дополнительно строилась линейная регрессия $\log10\ f = a + b \cdot L$: отрицательный наклон b означает, что с увеличением длины слова частота в среднем убывает.

Наиболее частые служебные слова русского языка приведены в таблице 3.

Таблица 3 – Наиболее частые служебные слова русского языка (без лемматизации)

Слово	Длина L	Частота f	Отн. частота, ipm	Ранг
в	1	230 296	46220,5	1
и	1	172 762	34673,4	2
на	2	71 193	14288,5	3
с	1	58 594	11759,8	4
по	2	32 946	6612,3	5
из	2	27 528	5524,9	6
к	1	25 213	5060,3	7
не	2	23 898	4796,3	8
а	1	22 965	4609,1	9
для	3	19 065	3826,4	10
как	3	18 929	3799,1	11
что	3	18 702	3753,5	12
также	5	15 677	3146,4	13
до	2	13 949	2799,6	14
его	3	13 684	2746,4	15
за	2	13 445	2698,4	16
был	3	12 047	2417,8	17
при	3	11 568	2321,7	18
или	3	10 893	2186,2	19
во	2	9 151	1836,6	20

Наиболее частые служебные слова английского языка приведены в таблице 4.

Таблица 4 – Наиболее частые служебные слова английского языка (без лемматизации)

Слово	Длина L	Частота f	Отн. частота, ipm	Ранг
the	3	356 297	71227,4	1
of	2	194 674	38917,3	2
and	3	156 876	31361,1	3
in	2	132 344	26456,9	4
to	2	104 421	20874,8	5
a	1	97 643	19519,8	6
is	2	47 705	9536,7	7
as	2	44 839	8963,8	8
was	3	43 391	8674,3	9
by	2	37 437	7484,0	10
for	3	37 364	7469,4	11
that	4	35 438	7084,4	12
with	4	34 760	6948,9	13
on	2	30 733	6143,8	14
from	4	25 794	5156,5	15
his	3	22 576	4513,2	16
are	3	21 605	4319,1	17
it	2	21 605	4319,1	17
an	2	21 435	4285,1	19
at	2	19 759	3950,0	20

Результаты корреляционного анализа для всех четырех словарей приведены в таблице 5. Коэффициенты Пирсона рассчитаны между длиной слова и логарифмом частоты, коэффициенты Спирмена — между длиной и абсолютной частотой.

Таблица 5 – Связь длины служебного слова и его частоты

Словарь	Служ. слов	r (Пирсон, L–log f)	ρ (Спирмен, L–f)	Наклон b	R^2
Русский, без лемматизации	151	-0,297	-0,319	-0,207	0,088
Русский, с лемматизацией	93	-0,381	-0,400	-0,227	0,145
Английский, без лемматизации	164	-0,485	-0,479	-0,246	0,235
Английский, с лемматизацией	145	-0,492	-0,488	-0,264	0,242

На рисунке 3 показаны зависимости для русского языка, на рисунке 4 — для английского. Слева представлена относительная частота служебных слов в зависимости от длины, справа — логарифм частоты и линия линейной регрессии. Для наглядности подписаны наиболее частые слова.

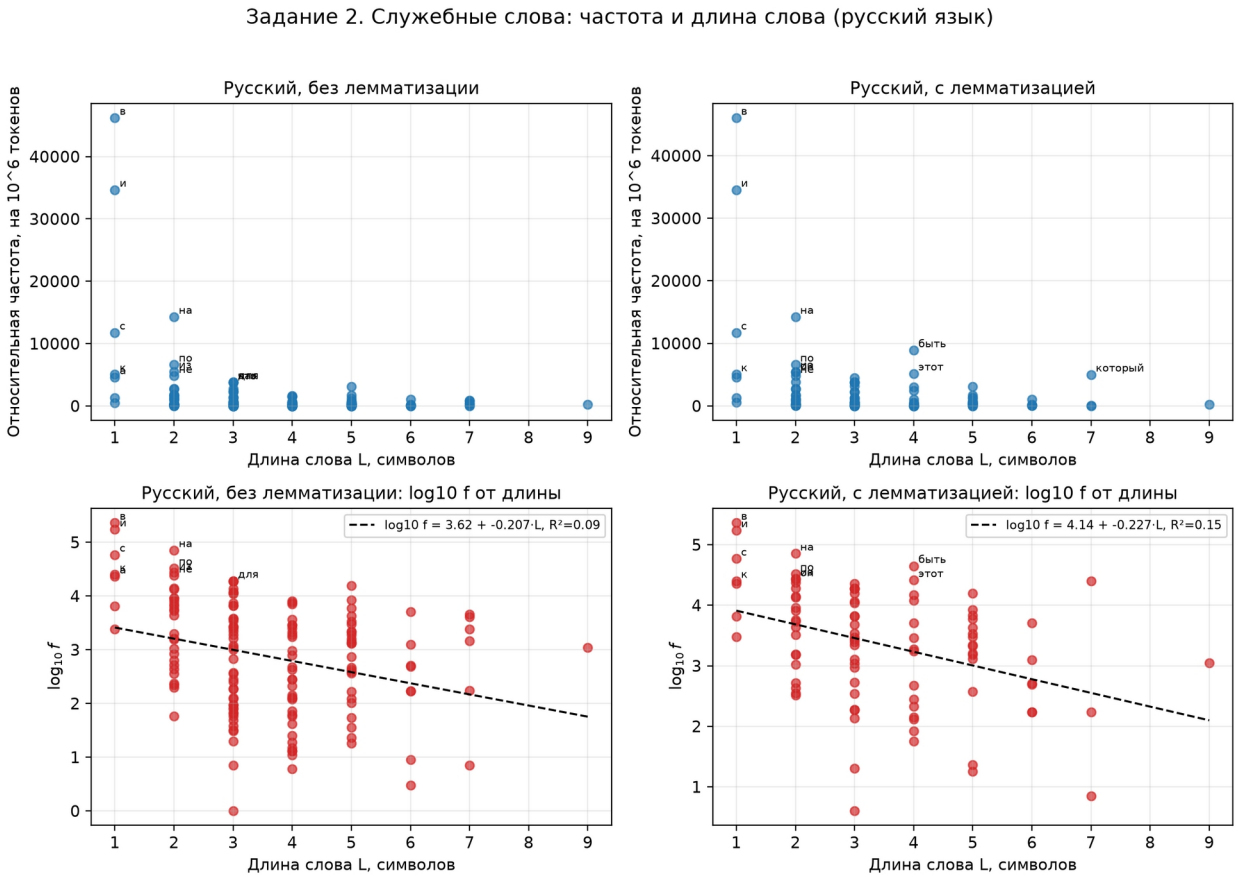


Рисунок 3 – Частота и длина служебных слов русского языка

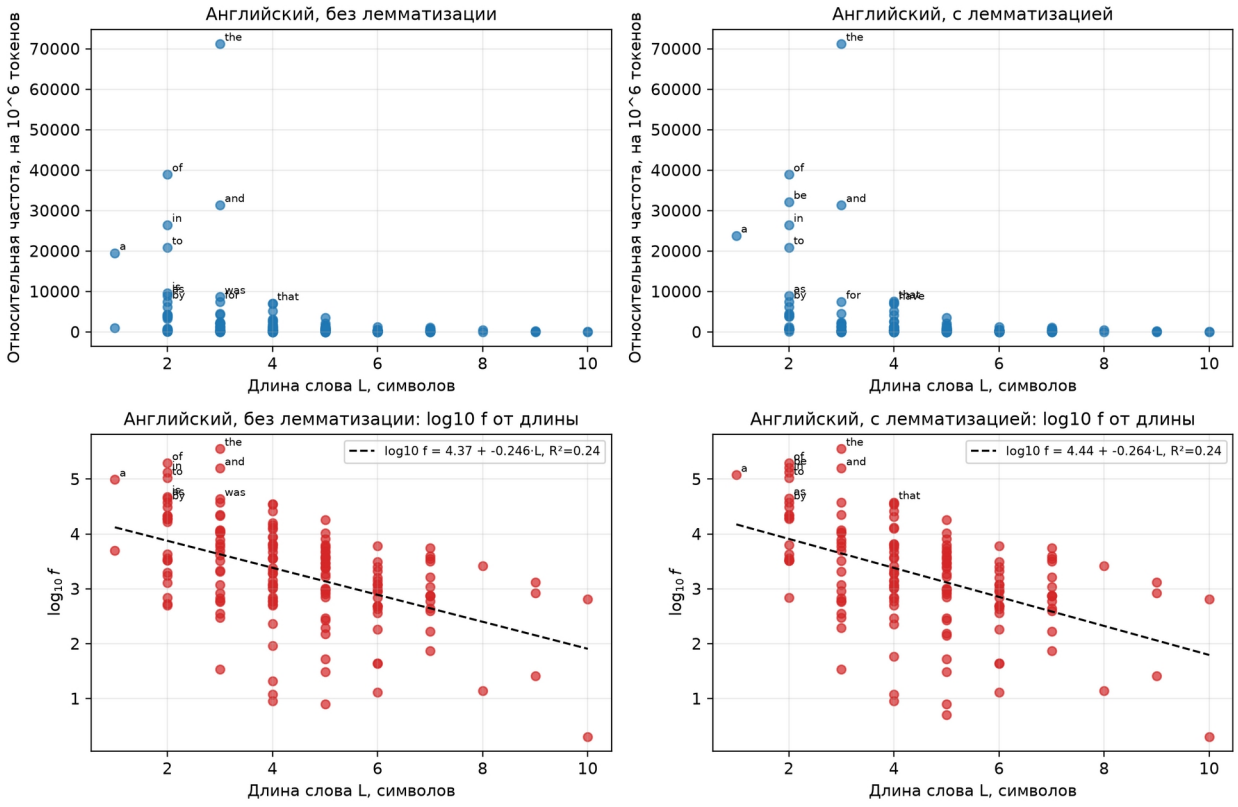


Рисунок 4 – Частота и длина служебных слов английского языка

Во всех словарях коэффициенты корреляции отрицательные и статистически значимые ($p < 0{,}001$). Для русского языка коэффициент Пирсона между длиной и логарифмом частоты составляет около −0,30…−0,38, коэффициент Спирмена — около −0,32…−0,40. Для английского языка связь выражена сильнее: $r \approx -0{,}48\ldots-0{,}49$, $\rho \approx -0{,}48\ldots-0{,}49$. Наклон регрессии b находится в диапазоне от −0,21 до −0,26: каждая дополнительная буква в среднем уменьшает log10 частоты примерно на 0,21–0,26, то есть частота падает в 1,6–1,8 раза.

При этом коэффициент детерминации R^2 составляет всего 0,09–0,24. Это означает, что длина слова объясняет лишь часть разброса частот: на частоту влияют также семантика, синтаксическая роль, омонимия и другие факторы. Тем не менее общая тенденция выражена отчетливо и согласуется с эмпирическим законом Ципфа: короткие служебные слова в среднем значительно частотнее длинных.

Вывод по заданию 2: эмпирический закон Ципфа для служебных слов выполняется качественно. Связь длины и частоты отрицательная и статистически значимая, однако она не является строго обратно пропорциональной; корректнее говорить о выраженной тенденции, а не о точной формуле.

ЗАДАНИЕ 3. РАСЧЕТ КОЭФФИЦИЕНТА D ЖУЙАНА

Коэффициент D Жуйана характеризует равномерность распределения слова по разным сегментам корпуса. Для его расчета корпус разбивается на n равных сегментов, в каждом сегменте подсчитывается частота слова, после чего вычисляются средняя частота μ и среднее квадратическое отклонение σ:

$$D = 1 - \sigma / (\mu \cdot \sqrt{(n - 1)}),$$

где μ — средняя частота слова по сегментам; σ — среднее квадратическое отклонение частоты по сегментам (с делением на n); n — число сегментов.

Значение D близко к 1, если слово встречается во всех сегментах примерно с одинаковой относительной частотой. Чем менее равномерно распределено слово, тем меньше D. Для расчета использовался корпус объемом 5 млн словоупотреблений, разбитый на 4 равных сегмента по 1,25 млн токенов. В каждом сегменте подсчитывались частоты слов из топ-1000 соответствующего частотного словаря. Частоты и ранги в таблицах берутся из исходных частотных словарей, а коэффициент D — из сегментных подсчетов.

Результаты для десяти самых частых слов каждого словаря приведены в таблице 6. Относительная частота указана в ipm (instances per million) — число вхождений на 1 млн токенов.

Таблица 6 – Коэффициент D Жуйана для наиболее частых слов

Словарь	Слово	Отн. частота, ipm	Ранг	D
Русский, без лемматизации	в	46220,5	1	0,977
Русский, без лемматизации	и	34673,4	2	0,991
Русский, без лемматизации	на	14288,5	3	0,970
Русский, без лемматизации	с	11759,8	4	0,981
Русский, без лемматизации	по	6612,3	5	0,962
Русский, без лемматизации	из	5524,9	6	0,981
Русский, без лемматизации	года	5106,6	7	0,947
Русский, без лемматизации	к	5060,3	8	0,970
Русский, без лемматизации	не	4796,3	9	0,961
Русский, без лемматизации	году	4650,8	10	0,973
Русский, с лемматизацией	в	46056,7	1	0,977
Русский, с лемматизацией	и	34550,5	2	0,991
Русский, с лемматизацией	на	14237,7	3	0,970
Русский, с лемматизацией	год	13180,1	4	0,960
Русский, с лемматизацией	с	11718,0	5	0,981
Русский, с лемматизацией	быть	8887,0	6	0,971
Русский, с лемматизацией	по	6588,9	7	0,962
Русский, с лемматизацией	из	5505,3	8	0,981
Русский, с лемматизацией	он	5354,1	9	0,960
Русский, с лемматизацией	этот	5176,1	10	0,983
Английский, без лемматизации	the	71227,4	1	0,981
Английский, без лемматизации	of	38917,3	2	0,975
Английский, без лемматизации	and	31361,1	3	0,993
Английский, без лемматизации	in	26456,9	4	0,985

Словарь	Слово	Отн. частота, ipm	Ранг	D
Английский, без лемматизации	to	20874,8	5	0,988
Английский, без лемматизации	a	19519,8	6	0,985
Английский, без лемматизации	is	9536,7	7	0,951
Английский, без лемматизации	as	8963,8	8	0,986
Английский, без лемматизации	was	8674,3	9	0,961
Английский, без лемматизации	s	7635,2	10	0,997
Английский, с лемматизацией	the	71227,4	1	0,981
Английский, с лемматизацией	of	38917,3	2	0,975
Английский, с лемматизацией	be	32123,2	3	0,983
Английский, с лемматизацией	and	31361,1	4	0,993
Английский, с лемматизацией	in	26459,9	5	0,985
Английский, с лемматизацией	a	23804,9	6	0,986
Английский, с лемматизацией	to	20919,2	7	0,988
Английский, с лемматизацией	as	8963,8	8	0,986
Английский, с лемматизацией	s	7669,2	9	0,997
Английский, с лемматизацией	that	7566,2	10	0,977

Чтобы проследить зависимость D от частотной зоны, все слова топ-1000 были разбиты на три группы по рангу: 1–10, 11–100 и 101–1000. Средние значения D приведены в таблице 7.

Таблица 7 – Средний коэффициент D по частотным зонам

Словарь	Ранги	Слов	Средний D	Медиана D	Мин. D	Макс. D
Русский, без лемматизации	1–10	10	0,971	0,972	0,947	0,991
Русский, без лемматизации	11–100	90	0,908	0,935	0,573	0,992
Русский, без лемматизации	101–1000	900	0,869	0,897	0,465	0,997
Русский, с лемматизацией	1–10	10	0,974	0,974	0,960	0,991
Русский, с лемматизацией	11–100	90	0,910	0,940	0,602	0,995
Русский, с лемматизацией	101–1000	900	0,870	0,900	0,186	0,993
Английский, без лемматизации	1–10	10	0,980	0,985	0,951	0,997
Английский, без лемматизации	11–100	90	0,947	0,965	0,703	0,993
Английский, без лемматизации	101–1000	900	0,877	0,908	0,053	0,987
Английский, с лемматизацией	1–10	10	0,985	0,985	0,975	0,997
Английский, с лемматизацией	11–100	90	0,945	0,962	0,703	0,993
Английский, с лемматизацией	101–1000	900	0,880	0,908	0,245	0,996

На рисунке 5 показано изменение коэффициента D с ростом ранга для русского языка, на рисунке 6 — для английского. Точки соответствуют отдельным словам, линии — скользящая медиана, помогающая увидеть общую тенденцию.

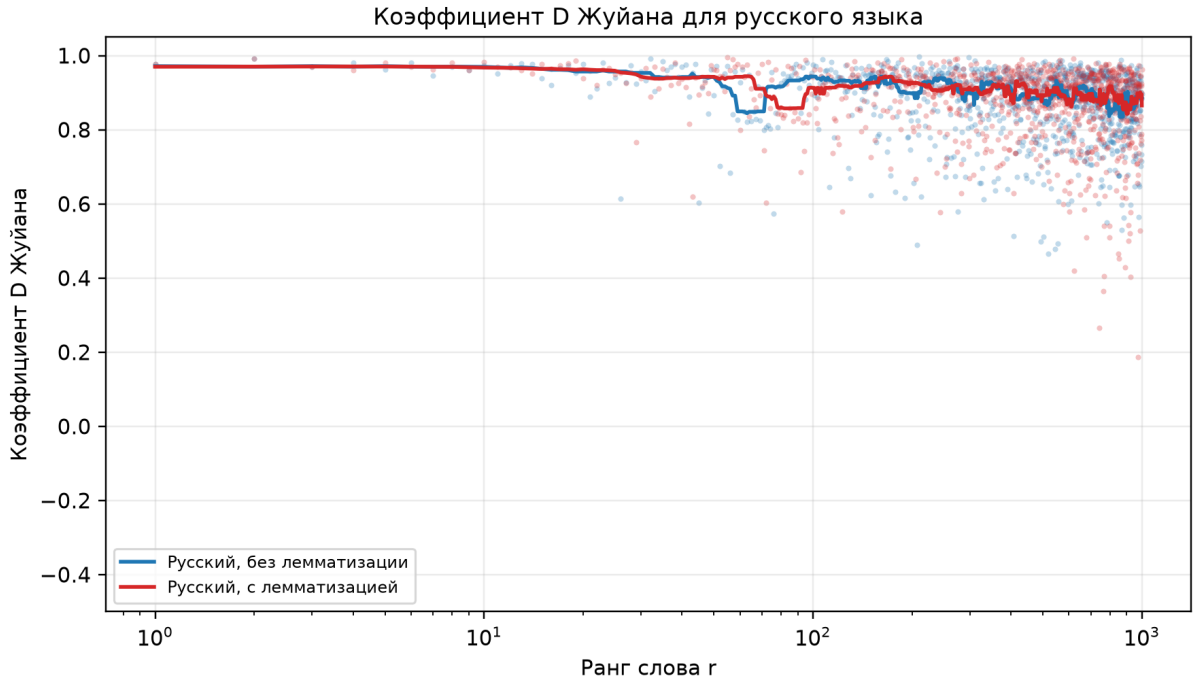


Рисунок 5 – Коэффициент D Жуйана в зависимости от ранга слова (русский язык)

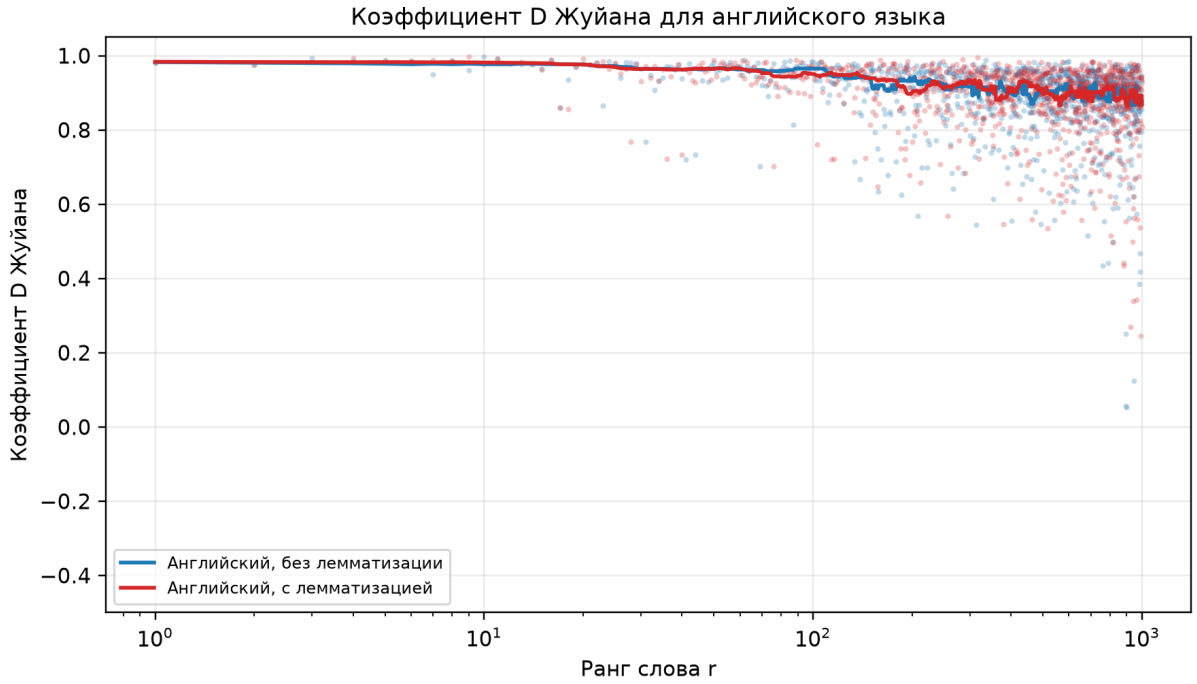


Рисунок 6 – Коэффициент D Жуйана в зависимости от ранга слова (английский язык)

Для самых частотных слов средний D составляет 0,97–0,99. Это ожидаемо: предлоги, союзы, местоимения и вспомогательные глаголы встречаются во всех сегментах корпуса и распределены по ним достаточно равномерно. При переходе к рангам 11–100 средний D снижается до 0,91–0,95, а для рангов 101–1000 — до 0,87–0,88. Разброс внутри последней группы

значительно больше: минимальные значения опускаются до 0,05–0,47, что соответствует словам, привязанным к отдельным темам или статьям.

Различия между словарями с лемматизацией и без нее невелики. Лемматизация объединяет словоформы в одну лемму, поэтому частоты становятся более устойчивыми, но общая картина сохраняется: служебная лексика распределена равномерно, а содержательная — менее равномерно.

Вывод по заданию 3: коэффициент D Жуйана подтверждает ожидаемую закономерность. Чем выше частота и «служебнее» слово, тем ближе D к единице; с ростом ранга и переходом к тематической лексике равномерность распределения падает. Коэффициент D является удобной количественной мерой равномерности распределения слов по сегментам корпуса.

ЗАКЛЮЧЕНИЕ

В работе проведено статистическое исследование четырех частотных словарей, построенных по корпусу русской и английской Википедии: двух словарей без лемматизации и двух словарей с лемматизацией.

Проверка закона Ципфа показала, что произведение частоты на ранг приблизительно постоянно в средней части частотного списка. В диапазоне рангов 100–5000 коэффициент детерминации степенной аппроксимации превышает 0,98, а наклон α близок к −1. На краях списка закон нарушается, что типично для реальных корпусов.

Проверка эмпирического закона Ципфа для служебных слов выявила статистически значимую отрицательную корреляцию между длиной слова и его частотой. Для английского языка связь оказалась несколько сильнее, чем для русского. При этом зависимость не является строго обратно пропорциональной: длина объясняет лишь 9–24 % разброса частот.

Расчет коэффициента D Жуйана показал, что наиболее частотные слова распределены по сегментам корпуса очень равномерно (D ≈ 0,97–0,99), а с ростом ранга равномерность снижается (D ≈ 0,87–0,88 для рангов 101–1000). Это соответствует содержательному смыслу коэффициента и подтверждает корректность выполненной сегментации корпуса.

Таким образом, все три задания выполнены, расчеты воспроизводимы, а построенные графики и таблицы согласованно описывают статистические свойства полученных частотных словарей.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Задание на расчетно-графическую работу № 2. Статистические исследования на базе корпуса и частотных словарей. Минск, 2026.

2. Wikimedia Foundation. Wikipedia. Dump 20231101 [Электронный ресурс]. URL: https://huggingface.co/datasets/wikimedia/wikipedia (дата обращения: 01.11.2026).

3. Zipf G. K. Human Behavior and the Principle of Least Effort. Cambridge: Addison-Wesley, 1949. 573 p.

4. Juilland A., Chang-Rodriguez E., Beltran J. V. Frequency Dictionary of Spanish Words. The Hague: Mouton, 1964.

5. Manning C. D., Schütze H. Foundations of Statistical Natural Language Processing. Cambridge: MIT Press, 1999. 680 p.

6. Баранов А. Н. Введение в прикладную лингвистику. М.: Эдиториал УРСС, 2001. 360 с.