Белорусский государственный университет
Факультет прикладной математики и информатики

Кафедра информационных систем управления

РАСЧЕТНО-ГРАФИЧЕСКАЯ РАБОТА № 2

Статистические исследования на базе частотных словарей
русского и английского языков

Выполнил:
студент [курс] курса [группа] группы
[ФИО студента]

Минск, 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....3
ЗАДАНИЕ 1. ЗАКОН ЦИПФА.....4
ЗАДАНИЕ 2. ЭМПИРИЧЕСКИЙ ЗАКОН ЦИПФА.....7
ЗАДАНИЕ 3. РАСЧЕТ КОЭФФИЦИЕНТА D ЖУЙАНА.....9
ЗАКЛЮЧЕНИЕ.....11
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....12

ВВЕДЕНИЕ

Цель работы — статистическое исследование частотных словарей, построенных по корпусу русской и английской Википедии. Исследование включает проверку закона Ципфа, проверку эмпирического закона Ципфа для служебных слов и расчет коэффициента D Жуйана.

Исходные данные — четыре частотных словаря проекта nlp_uni: русский и английский, каждый в двух вариантах — без лемматизации и с лемматизацией. Словари содержат абсолютные частоты слов (словоформ или лемм), общее число токенов и число уникальных единиц. Объем каждого словаря — около 5 млн словоупотреблений.

Для расчетов использовались язык программирования Python, библиотеки pandas, NumPy, SciPy и Matplotlib. Все вычисления и графики воспроизводятся в ноутбуках 01_zipf_law.ipynb, 02_zipf_empirical_function_words.ipynb и 03_juilland.ipynb.

Отчет состоит из трех заданий. В первом задании проверяется основной закон Ципфа, во втором — его эмпирический вариант для служебных слов, в третьем — рассчитывается коэффициент Жуйана для наиболее частых слов.

ЗАДАНИЕ 1. ЗАКОН ЦИПФА

Закон Ципфа утверждает, что произведение частоты слова f на его ранг r в частотном списке есть приблизительно постоянная величина:

$$f \cdot r = c,$$

где f — частота встречаемости слова в тексте; r — ранг слова в частотном списке; c — эмпирическая постоянная (коэффициент Ципфа).

Ранг присваивался словам по убыванию частоты. Для каждого слова вычислялось произведение f · r, а коэффициент c оценивался как медиана этого произведения в диапазоне рангов 100–5000. Характеристики словарей приведены в таблице 1.

Таблица 1 – Характеристики частотных словарей

Словарь	Язык	Лемматизация	Токенов	Уникальных слов
Русский, без лемматизации	Русский	Нет	4 982 552	314 763
Русский, с лемматизацией	Русский	Да	5 000 251	181 819
Английский, без лемматизации	Английский	Нет	5 002 249	142 303
Английский, с лемматизацией	Английский	Да	5 002 249	124 040

Полученные значения коэффициента c приведены в таблице 2.

Таблица 2 – Коэффициент Ципфа c

Словарь	c
Русский, без лемматизации	591 965
Русский, с лемматизацией	656 775
Английский, без лемматизации	581 872
Английский, с лемматизацией	567 200

На рисунке 1 показаны графики для русского языка, на рисунке 2 — для английского. Верхние панели содержат эмпирические точки в логарифмических координатах и прямую f = c / r. Нижние панели показывают произведение f · r; горизонтальная линия соответствует коэффициенту c.

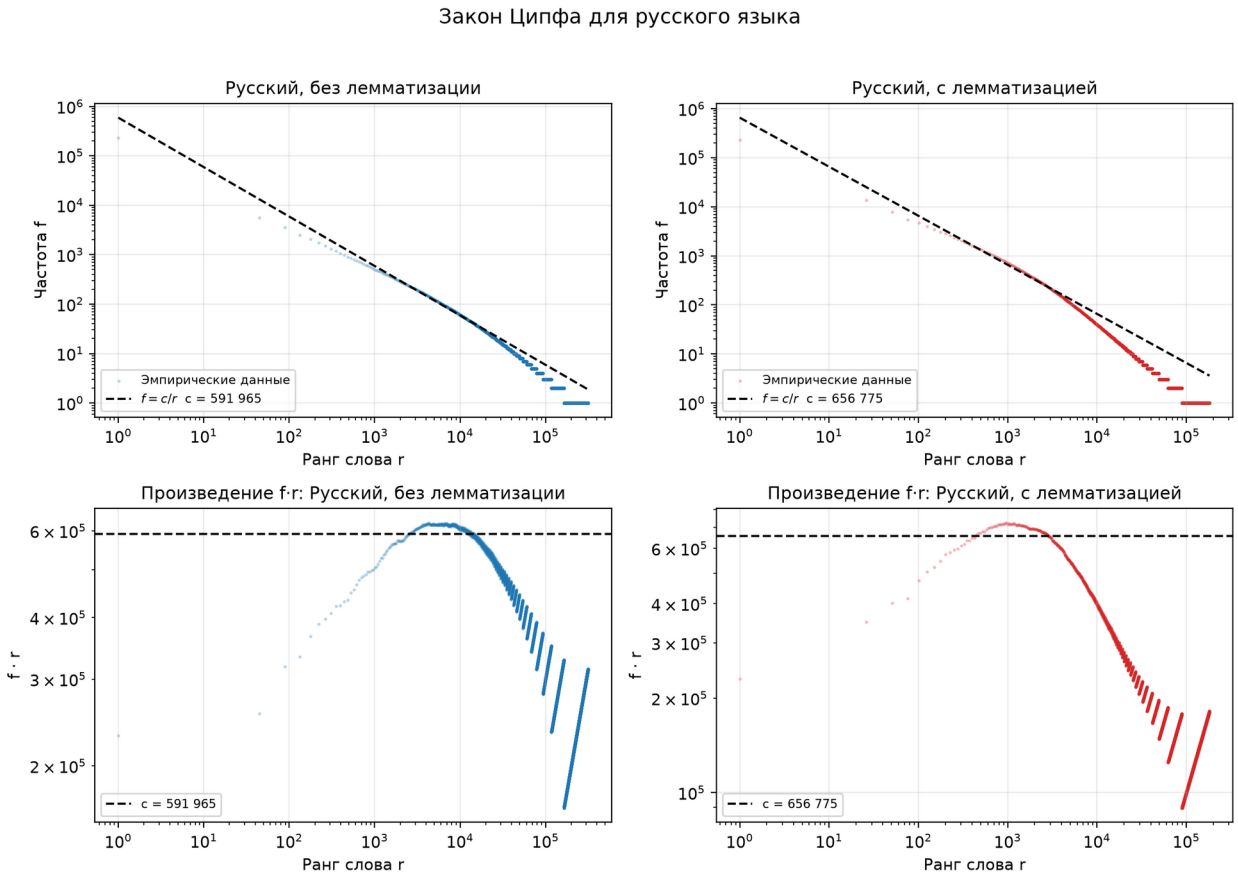


Рисунок 1 – Закон Ципфа для русского языка

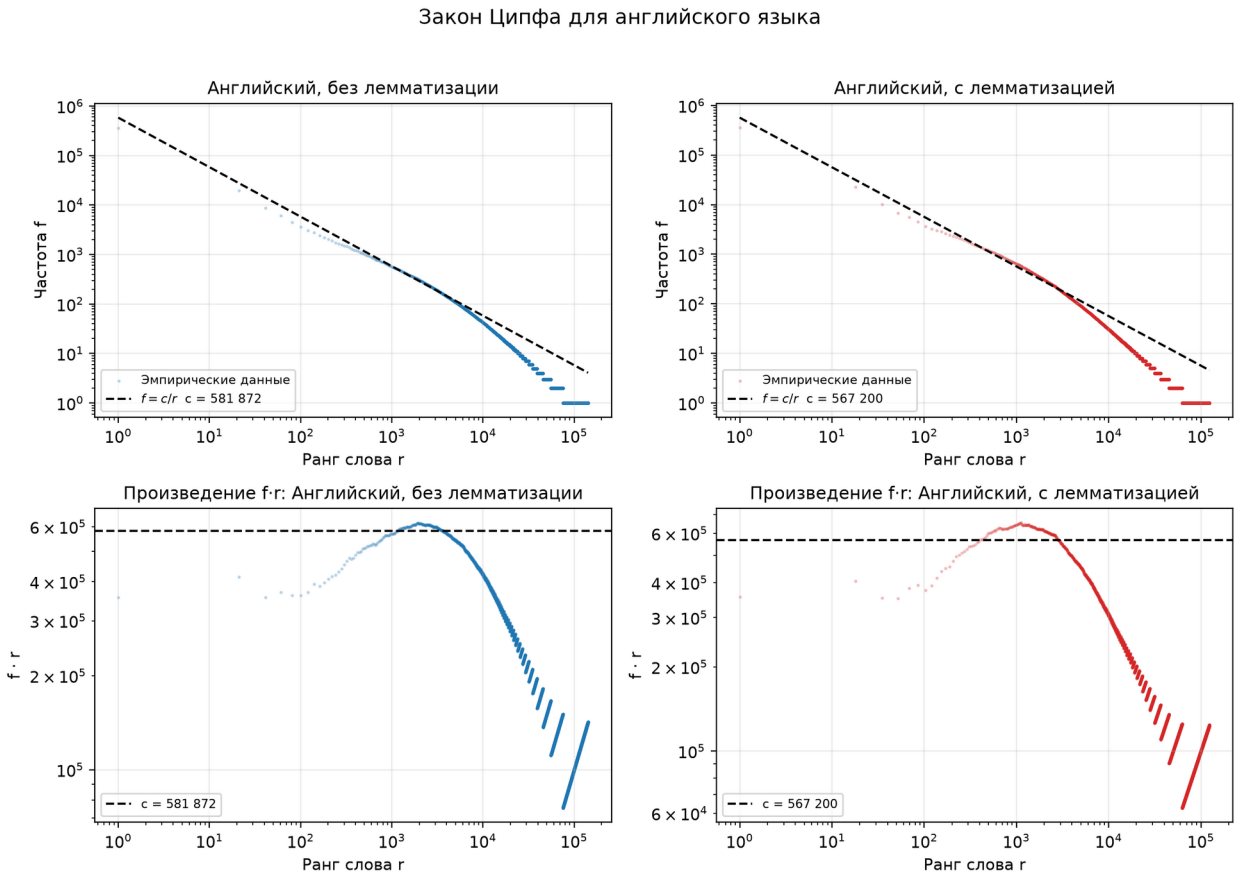


Рисунок 2 – Закон Ципфа для английского языка

Для русского словаря без лемматизации c = 591 965, с лемматизацией — 656 775. Для английского словаря без лемматизации c = 581 872, с лемматизацией — 567 200.

Во всех четырех словарях произведение $f \cdot r$ в средней части частотного списка остается приблизительно постоянным. На краях списка наблюдаются систематические отклонения: у самых частых слов произведение повышено, у редких — понижено.

Вывод по заданию 1: закон Ципфа для построенных частотных словарей выполняется приближенно. Коэффициент c зависит от языка и от способа подготовки словаря и составляет примерно 0,57–0,66 млн в рассматриваемом диапазоне рангов.

ЗАДАНИЕ 2. ЭМПИРИЧЕСКИЙ ЗАКОН ЦИПФА

Эмпирический закон Ципфа утверждает, что длина слова обратно пропорциональна его частоте: более короткие слова в среднем встречаются чаще длинных. Проверка выполнялась на списке служебных слов: предлогов, союзов, частиц, местоимений и вспомогательных глаголов.

Список служебных слов был составлен вручную и затем отфильтрован по наличию в соответствующем частотном словаре. Для каждого слова определялись длина L в символах и абсолютная частота f. Связь оценивалась коэффициентом корреляции Пирсона: отрицательное значение означает, что с увеличением длины слова частота в среднем убывает.

Результаты корреляционного анализа приведены в таблице 3.

Таблица 3 – Связь длины служебного слова и его частоты

Словарь	Служебных слов	r (Пирсон)
Русский, без лемматизации	151	-0,311
Русский, с лемматизацией	93	-0,330
Английский, без лемматизации	164	-0,287
Английский, с лемматизацией	145	-0,331

На рисунке 3 показаны зависимости для русского языка, на рисунке 4 — для английского. По оси абсцисс отложена длина слова, по оси ординат — относительная частота.

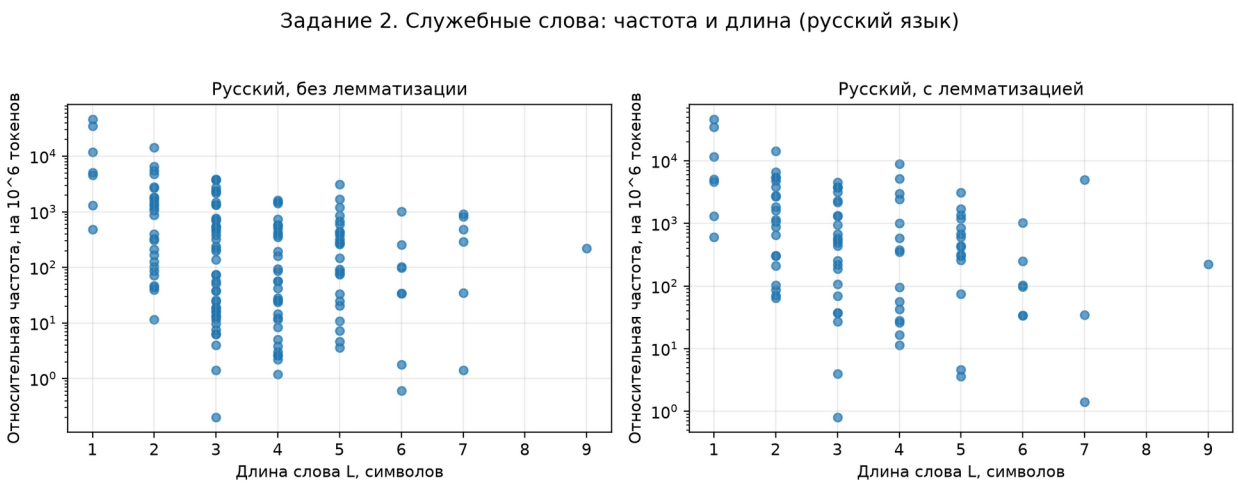


Рисунок 3 – Частота и длина служебных слов русского языка

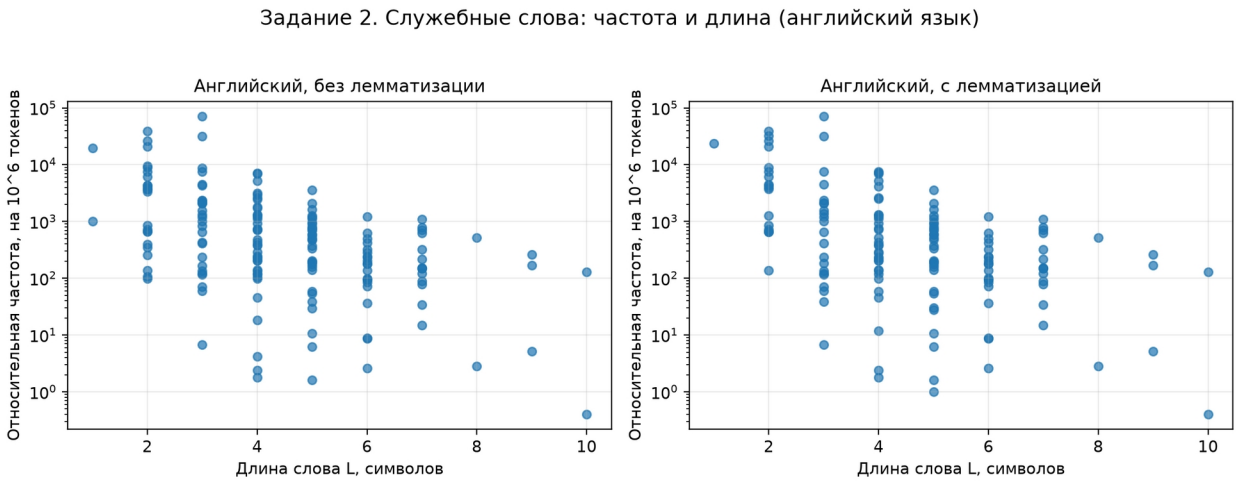


Рисунок 4 – Частота и длина служебных слов английского языка

Во всех словарях коэффициенты корреляции отрицательные: r = -0,311, -0,330, -0,287, -0,331. Это означает, что более короткие служебные слова в среднем встречаются чаще длинных.

При этом связь умеренная: длина слова объясняет лишь часть разброса частот. На частоту влияют также семантика, синтаксическая роль, омонимия и другие факторы.

Вывод по заданию 2: эмпирический закон Ципфа для служебных слов выполняется качественно. Связь длины и частоты отрицательная и статистически значимая, однако она не является строго обратно пропорциональной.

ЗАДАНИЕ 3. РАСЧЕТ КОЭФФИЦИЕНТА D ЖУЙАНА

Коэффициент D Жуйана характеризует равномерность распределения слова по разным сегментам корпуса. Для его расчета корпус разбивается на n равных сегментов, в каждом сегменте подсчитывается частота слова, после чего вычисляются средняя частота μ и среднее квадратическое отклонение σ:

$$D = 1 - \sigma / (\mu \cdot \sqrt{(n - 1)}),$$

где μ — средняя частота слова по сегментам; σ — среднее квадратическое отклонение частоты по сегментам (с делением на n); n — число сегментов.

Для расчета использовался корпус объемом 5 млн словоупотреблений, разбитый на 4 равных сегмента по 1,25 млн токенов. В каждом сегменте подсчитывались частоты слов из топ-1000 соответствующего частотного словаря. В таблицу 4 включены 10 самых частых слов каждого словаря.

Результаты расчета коэффициента D приведены в таблице 4.

Таблица 4 – Коэффициент D Жуйана для наиболее частых слов

Словарь	Слово	Отн. частота, ipm	Ранг	D
Русский, без лемматизации	в	46220,5	1	0,977
Русский, без лемматизации	и	34673,4	2	0,991
Русский, без лемматизации	на	14288,5	3	0,970
Русский, без лемматизации	с	11759,8	4	0,981
Русский, без лемматизации	по	6612,3	5	0,962
Русский, без лемматизации	из	5524,9	6	0,981
Русский, без лемматизации	года	5106,6	7	0,947
Русский, без лемматизации	к	5060,3	8	0,970
Русский, без лемматизации	не	4796,3	9	0,961
Русский, без лемматизации	году	4650,8	10	0,973
Русский, с лемматизацией	в	46056,7	1	0,977
Русский, с лемматизацией	и	34550,5	2	0,991
Русский, с лемматизацией	на	14237,7	3	0,970
Русский, с лемматизацией	год	13180,1	4	0,960
Русский, с лемматизацией	с	11718,0	5	0,981
Русский, с лемматизацией	быть	8887,0	6	0,971
Русский, с лемматизацией	по	6588,9	7	0,962
Русский, с лемматизацией	из	5505,3	8	0,981
Русский, с лемматизацией	он	5354,1	9	0,960
Русский, с лемматизацией	этот	5176,1	10	0,983
Английский, без лемматизации	the	71227,4	1	0,981
Английский, без лемматизации	of	38917,3	2	0,975
Английский, без лемматизации	and	31361,1	3	0,993
Английский, без лемматизации	in	26456,9	4	0,985
Английский, без лемматизации	to	20874,8	5	0,988
Английский, без лемматизации	a	19519,8	6	0,985
Английский, без лемматизации	is	9536,7	7	0,951
Английский, без лемматизации	as	8963,8	8	0,986
Английский, без лемматизации	was	8674,3	9	0,961
Английский, без лемматизации	s	7635,2	10	0,997
Английский, с лемматизацией	the	71227,4	1	0,981
Английский, с лемматизацией	of	38917,3	2	0,975
Английский, с лемматизацией	be	32123,2	3	0,983
Английский, с лемматизацией	and	31361,1	4	0,993
Английский, с лемматизацией	in	26459,9	5	0,985
Английский, с лемматизацией	a	23804,9	6	0,986
Английский, с лемматизацией	to	20919,2	7	0,988
Английский, с лемматизацией	as	8963,8	8	0,986
Английский, с лемматизацией	s	7669,2	9	0,997
Английский, с лемматизацией	that	7566,2	10	0,977

Для десяти самых частых слов каждого словаря коэффициент D находится в диапазоне от 0,947 до 0,997. Это близко к единице: наиболее частотные слова встречаются во всех сегментах корпуса примерно с одинаковой относительной частотой.

Вывод по заданию 3: коэффициент D Жуйана для наиболее частых слов близок к 1, что подтверждает равномерность их распределения по сегментам корпуса.

ЗАКЛЮЧЕНИЕ

В работе проведено статистическое исследование четырех частотных словарей, построенных по корпусу русской и английской Википедии: двух словарей без лемматизации и двух словарей с лемматизацией.

Проверка закона Ципфа показала, что произведение частоты на ранг приблизительно постоянно в средней части частотного списка. Коэффициент с составляет примерно 0,57–0,66 млн. На краях списка закон нарушается, что типично для реальных корпусов.

Проверка эмпирического закона Ципфа для служебных слов выявила статистически значимую отрицательную корреляцию между длиной слова и его частотой. Связь умеренная, поэтому закон выполняется качественно, а не как строгая обратная пропорциональность.

Расчет коэффициента D Жуйана показал, что для наиболее частых слов D близок к 1. Это соответствует равномерному распределению высокочастотной лексики по сегментам корпуса.

Таким образом, все три задания выполнены, расчеты воспроизводимы, а построенные графики и таблицы описывают статистические свойства полученных частотных словарей.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Задание на расчетно-графическую работу № 2. Статистические исследования на базе корпуса и частотных словарей. Минск, 2026.

2. Wikimedia Foundation. Wikipedia. Dump 20231101 [Электронный ресурс]. URL: https://huggingface.co/datasets/wikimedia/wikipedia (дата обращения: 01.11.2026).

3. Zipf G. K. Human Behavior and the Principle of Least Effort. Cambridge: Addison-Wesley, 1949. 573 p.

4. Juilland A., Chang-Rodriguez E., Beltran J. V. Frequency Dictionary of Spanish Words. The Hague: Mouton, 1964.

5. Manning C. D., Schütze H. Foundations of Statistical Natural Language Processing. Cambridge: MIT Press, 1999. 680 p.

6. Баранов А. Н. Введение в прикладную лингвистику. М.: Эдиториал УРСС, 2001. 360 с.