Белорусский государственный университет
Факультет прикладной математики и информатики

Кафедра информационных систем управления

РАСЧЕТНО-ГРАФИЧЕСКАЯ РАБОТА № 3

Векторная модель текста

Выполнил:
студент 3 курса 12 группы
Дрозд Егор Павлович

Минск, 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....3
ЗАДАНИЕ 1. ВЕКТОРНАЯ МОДЕЛЬ ТЕКСТА.....4
ЗАКЛЮЧЕНИЕ.....9
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....10

ВВЕДЕНИЕ

Цель работы — построить векторные модели текстов на основе мультимножества слов для русского и английского языков и сравнить тексты с помощью меры сходства.

Исходные данные — по два текста из корпуса, собранного в работе №1. Корпус построен по датасету wikimedia/wikipedia версии 20231101. Для русского языка выбраны статьи «Литва» и «Кавказские Минеральные Воды», для английского — «Anarchism» и «Ayn Rand». Пары текстов близки по размеру, что позволяет корректно сравнивать векторные модели. Характеристики текстов приведены в таблице 1.

Таблица 1 – Исходные тексты

Язык	**Текст 1**	**Текст 2**	**Слов в тексте 1**	**Слов в тексте 2**
Русский	Литва	Кавказские Минеральные Воды	5 908	5 737
Английский	Anarchism	Ayn Rand	6 712	6 230

Для реализации использовались язык Python и библиотеки simplemma (лемматизация), NumPy (векторные операции), pandas (таблицы) и Matplotlib (график). Все вычисления воспроизводятся в ноутбуке 01_vector_models.ipynb и модуле vector_model.py.

В задании 1 необходимо выполнить токенизацию, нормализацию, удаление стоп-слов, построить модели one-hot encoding и TF, определить пересечение мультимножеств для one-hot модели и найти косинусный коэффициент для TF модели.

ЗАДАНИЕ 1. ВЕКТОРНАЯ МОДЕЛЬ ТЕКСТА

Векторная модель представляет текст в виде вектора признаков. В качестве признаков используются слова, входящие в общий словарь пары текстов. Мультимножество слов учитывает не только наличие слова, но и число его вхождений в текст.

1.1 Токенизация

Токенизация — разбиение текста на слова. Для русского языка использовалось регулярное выражение [а-яё]+, для английского — [a-z]+. Перед токенизацией удалялись знаки ударения, которые встречаются в русской Википедии, и все буквы приводились к нижнему регистру. Результаты токенизации приведены в таблице 2.

Таблица 2 – Результаты токенизации

Текст	Язык	Токенов	Уникальных токенов
Литва	Русский	5 332	2 579
Кавказские Минеральные Воды	Русский	5 446	2 507
Anarchism	Английский	6 790	1 914
Ayn Rand	Английский	6 236	1 763

1.2 Нормализация текста

В качестве нормализации применялась лемматизация библиотекой simplemma: словоформы приводились к начальной форме. Например, «Литвы» → «литва», «running» → «run», «was» → «be». Это уменьшает размер словаря и объединяет разные формы одного слова. Результаты нормализации приведены в таблице 3.

Таблица 3 – Результаты лемматизации

Текст	Язык	Токенов после лемматизации	Уникальных лемм
Литва	Русский	5 332	1 832
Кавказские Минеральные Воды	Русский	5 446	1 750
Anarchism	Английский	6 790	1 602
Ayn Rand	Английский	6 236	1 537

1.3 Удаление стоп-слов

Из текстов удалялись стоп-слова: предлоги, союзы, частицы, местоимения, вспомогательные глаголы и другие служебные слова. Использовался список служебных слов из РГР №2, который также лемматизировался, чтобы удалялись все словоформы. Дополнительно

удалялись одиночные буквы — артефакты токенизации. Результаты фильтрации приведены в таблице 4.

Таблица 4 – Результаты удаления стоп-слов

Текст	Язык	Токенов после стоп-слов	Уникальных слов
Литва	Русский	3 990	1 745
Кавказские Минеральные Воды	Русский	4 106	1 659
Anarchism	Английский	3 880	1 476
Ayn Rand	Английский	3 554	1 408

Таблица 5 – Топ-10 слов после удаления стоп-слов (русский язык)

№	Литва	Частота	Кавказские Минеральные Воды	Частота
1	год	163	вода	120
2	литва	159	минеральный	87
3	литовский	96	год	83
4	страна	36	кавказский	54
5	язык	32	курорт	52
6	население	29	кмв	51
7	территория	28	пятигорск	37
8	государство	25	источник	37
9	ссср	18	район	34
10	княжество	18	кисловодск	28

Таблица 6 – Топ-10 слов после удаления стоп-слов (английский язык)

№	Anarchism	Частота	Ayn Rand	Частота
1	anarchist	160	rand	175
2	anarchism	116	american	39
3	state	74	work	33
4	movement	38	philosopher	32
5	political	24	novel	29
6	group	24	review	26
7	society	22	idea	26
8	form	22	philosophy	25
9	anti	22	ayn	23
10	current	22	writer	23

1.4 Модель one-hot encoding

Для каждой пары текстов строился общий словарь — объединение словарей двух текстов. В one-hot модели компонента вектора равна 1, если слово встречается в тексте, и 0 в противном случае. Модель учитывает только наличие слова, но не его частоту. Характеристики модели приведены в таблице 7.

Таблица 7 – Модель one-hot encoding

Язык	Размер словаря	Единиц в матрице	Общих слов	Жаккар	Косинус
Русский	2 992	3 404	412	0,1377	0,2421
Английский	2 395	2 884	489	0,2042	0,3392

1.5 Модель TF (term frequency)

В TF-модели вес слова равен его относительной частоте в тексте:

$$TF(w, d) = n(w, d) / \Sigma\, n(w', d),$$

где n(w, d) — число вхождений слова w в текст d; сумма берётся по всем словам текста. Векторы строятся в общем словаре пары текстов. Наиболее весомые TF-термы приведены в таблицах 8 и 9.

Таблица 8 – Топ-10 TF-термов (русский язык)

№	Литва	TF	Кавказские Минеральные Воды	TF
1	год	0,04085	вода	0,02923
2	литва	0,03985	минеральный	0,02119
3	литовский	0,02406	год	0,02021
4	страна	0,00902	кавказский	0,01315
5	язык	0,00802	курорт	0,01266
6	население	0,00727	кмв	0,01242
7	территория	0,00702	источник	0,00901
8	государство	0,00627	пятигорск	0,00901
9	великий	0,00451	район	0,00828
10	княжество	0,00451	кисловодск	0,00682

Таблица 9 – Топ-10 TF-термов (английский язык)

№	Anarchism	TF	Ayn Rand	TF
1	anarchist	0,04124	rand	0,04924
2	anarchism	0,02990	american	0,01097
3	state	0,01907	work	0,00929
4	movement	0,00979	philosopher	0,00900
5	group	0,00619	novel	0,00816
6	political	0,00619	idea	0,00732
7	anti	0,00567	review	0,00732
8	current	0,00567	philosophy	0,00703
9	form	0,00567	ayn	0,00647
10	society	0,00567	writer	0,00647

1.6 Пересечение мультимножеств для one-hot модели

Для one-hot векторов пересечение — это слова, которые есть в обоих текстах (общие уникальные слова). Дополнительно для исходных мультимножеств слов вычислялось пересечение с учётом кратностей:

$$|M1 \cap M2| = \Sigma\, min(n1(w), n2(w)).$$

Сходство множеств оценивалось коэффициентом Жаккара:

$$J = |V1 \cap V2| / |V1 \cup V2|,$$

где V1 и V2 — множества уникальных слов первого и второго текстов. Для one-hot векторов также вычислялся косинус. Результаты приведены в таблице 10.

Таблица 10 – Пересечение множеств и мультимножеств

Язык	Общих уникальных слов	Объединение	Пересечение мультимножеств	Жаккар	Косинус one-hot
Русский	412	2 992	900	0,1377	0,2421
Английский	489	2 395	1 061	0,2042	0,3392

Таблица 11 – Наиболее частые общие слова (русский язык)

№	Слово	В тексте 1	В тексте 2	Минимум
1	год	163	83	83
2	территория	28	21	21
3	первый	15	14	14
4	часть	12	16	12
5	государственный	14	10	10
6	край	10	14	10
7	состав	12	10	10
8	город	8	17	8
9	один	8	10	8
10	февраль	10	8	8

Таблица 12 – Наиболее частые общие слова (английский язык)

№	Слово	В тексте 1	В тексте 2	Минимум
1	state	74	22	22
2	political	24	19	19
3	philosophical	15	14	14
4	late	13	19	13
5	century	20	12	12
6	include	12	21	12
7	first	11	14	11
8	become	10	10	10
9	libertarian	10	11	10
10	take	15	10	10

1.7 Косинусный коэффициент для TF модели

Косинусная мера близости вычисляется по формуле

$$cos(v1, v2) = (v1 \cdot v2) / (||v1|| \cdot ||v2||).$$

Она не зависит от длины текста и принимает значения от 0 до 1: чем ближе значение к 1, тем более похожи частотные профили текстов. Результаты для TF модели приведены в таблице 13, сравнение моделей — в таблице 14.

Таблица 13 – Косинусный коэффициент для TF модели

Язык	Текст 1	Текст 2	Косинус TF
Русский	Литва	Кавказские Минеральные Воды	0,2838
Английский	Anarchism	Ayn Rand	0,1874

Таблица 14 – Сравнение one-hot и TF моделей

Язык	Косинус one-hot	Косинус TF
Русский	0,2421	0,2838
Английский	0,3392	0,1874

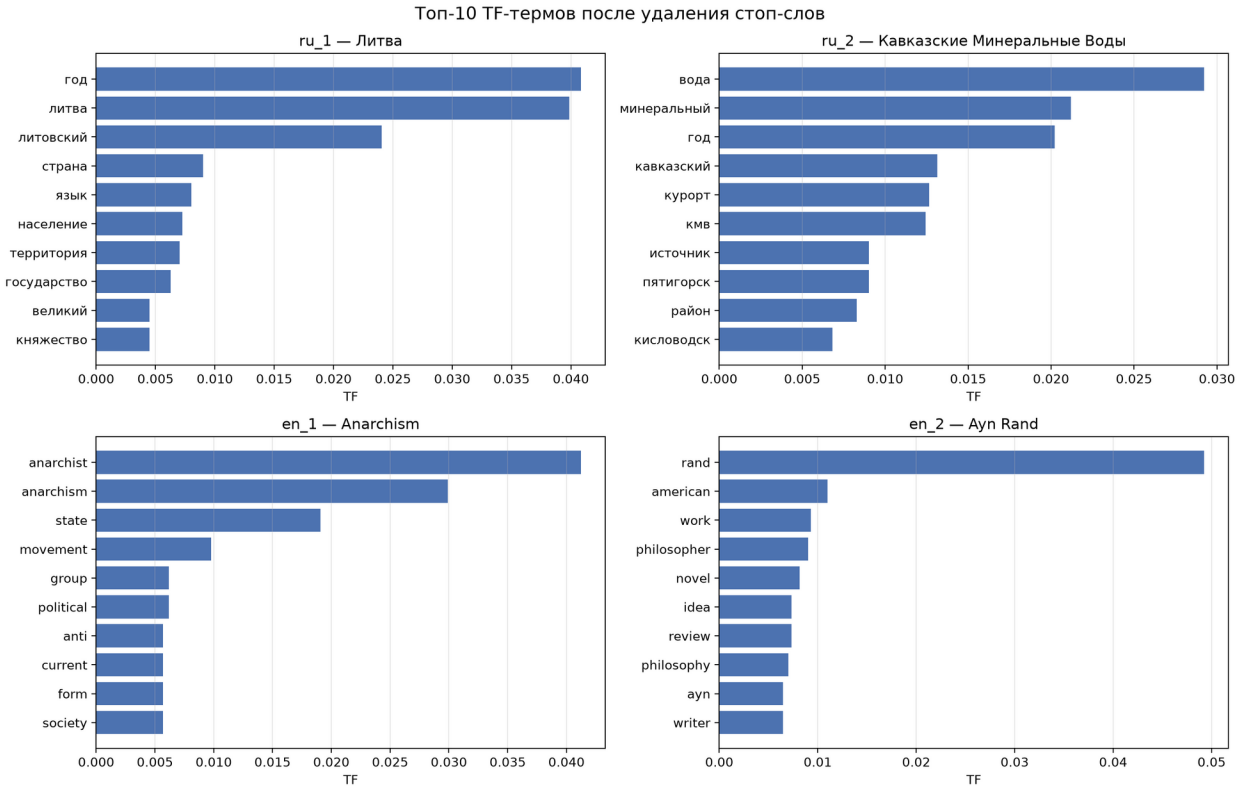


Рисунок 1 – Топ-10 TF-термов после удаления стоп-слов

Вывод по заданию 1. В ходе выполнения задания построены две векторные модели для двух пар текстов. После токенизации, лемматизации и удаления стоп-слов в каждом тексте остаётся около 3,5–4,1 тыс. значимых слов. One-hot модель учитывает только наличие слова, поэтому её косинус для русской пары равен примерно 0,24, для английской — примерно 0,34. TF модель дополнительно учитывает относительную частоту слов: косинус для русской пары составляет примерно 0,28, для английской — примерно 0,19. Пересечение мультимножеств с учётом кратностей больше числа общих уникальных слов (900 против 412 для русского языка и 1 061 против 489 для английского), что показывает повторяемость общих слов в обоих текстах.

ЗАКЛЮЧЕНИЕ

В работе реализовано задание 1 РГР №3: построены векторные модели текстов на основе мультимножества слов для русского и английского языков. Выполнены токенизация, лемматизация и удаление стоп-слов, построены модели one-hot encoding и TF, рассчитаны пересечение мультимножеств, коэффициент Жаккара и косинусная мера сходства.

Полученные результаты показывают, что one-hot модель отражает факт наличия общих слов, но не учитывает их частоту, тогда как TF модель более чувствительна к распределению частот. Для дальнейших заданий работы подготовленные нормализованные тексты можно использовать для построения Bag-of-words для 2-грамм, модели TF*IDF и сравнения лемматизации со стеммингом.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Wikimedia Foundation. Wikimedia Wikipedia dataset, version 20231101 [Электронный ресурс]. — Hugging Face. — Режим доступа: https://huggingface.co/datasets/wikimedia/wikipedia.

2. simplemma: simple multilingual lemmatizer for Python [Электронный ресурс]. — Режим доступа: https://github.com/adbar/simplemma.

3. NumPy: the fundamental package for scientific computing with Python [Электронный ресурс]. — Режим доступа: https://numpy.org.

4. pandas: Python Data Analysis Library [Электронный ресурс]. — Режим доступа: https://pandas.pydata.org.

5. Matplotlib: Visualization with Python [Электронный ресурс]. — Режим доступа: https://matplotlib.org.

6. Корпус и частотные словари проекта nlp_uni, работа №1.